



Predicting Loan Default

Data-Driven Insights for Smarter Credit
Decisions


Luthfi Ridhoul Aziz



: <https://www.linkedin.com/in/luthfiridhoul/>



: <https://github.com/luthfiridhoul>





PHONE NUMBER

+62-811-3776-663

EMAIL ADDRESS

luthfiridhoulz@gmail.com

Profil

Saya **Luthfi Ridhoul Aziz**, lulusan **S1 Akuntansi** dari **Universitas Brawijaya** dengan IPK 3,58. Selama masa kuliah, saya aktif mengikuti berbagai kegiatan akademik maupun non-akademik yang mengasah kemampuan analisis, komunikasi, dan kerja sama tim.

Selain memiliki minat yang besar di bidang **finance**, saat ini saya juga mendalami dunia data, khususnya **Data Science** dan **Data Analysis**, untuk mengembangkan potensi saya di dunia kerja.

Untuk mendukung hal tersebut, saya mengikuti **Bootcamp Data Science** di **Dibimbing.id** selama kurang lebih 6 bulan, mempelajari berbagai keterampilan seperti pengolahan data, visualisasi, serta pengembangan model Machine Learning untuk pemecahan masalah bisnis.

Goals

Business Problem:

Banyak institusi keuangan mengalami kerugian karena tingkat gagal bayar (loan default) yang tinggi. Perlu adanya model prediksi untuk mengidentifikasi nasabah yang berpotensi gagal bayar sebelum pinjaman diberikan.

Analytical Goal:

Mengembangkan model klasifikasi yang dapat memprediksi risiko gagal bayar nasabah berdasarkan informasi profil dan pinjamannya.

Business Goal:

Mengurangi kerugian finansial dan meningkatkan efisiensi penyaluran kredit dengan menolak pengajuan berisiko tinggi, atau menyesuaikan syarat pinjaman bagi calon peminjam yang memiliki kemungkinan default tinggi.

...





Dataset

Dataset ini berisi **255.347 data** pengajuan pinjaman dari berbagai peminjam, lengkap dengan profil nasabah, detail pinjaman, dan status gagal bayar. Yang dimana terbagi atas 18 kolom dan 255.347 baris.

Dataset ini dipakai untuk:

- Menganalisis pola dan faktor yang mempengaruhi gagal bayar
- Membangun model machine learning untuk memprediksi risiko kredit
- Memberikan insight bisnis untuk membantu perusahaan keuangan mengurangi risiko dan meningkatkan profitabilitas portofolio pinjaman.

Data Cleaning




- Tidak menemukan data kosong
- Menangani beberapa data duplicate dengan menghapus salah satunya
- Mendrop kolom 'LoanID'

Data Manipulation

- Melakukan Binary mapping untuk kolom Yes/No yaitu pada kolom **"HasMortgage"**, **"HasDependents"**, **"HasCoSigner"**.
- Melakukan One-hot encoding kolom multikategori yaitu pada kolom **"Education"**, **"EmploymentType"**, **"MaritalStatus"**, **"LoanPurpose"**.
- Melakukan scaling numerik pada kolom **"Age"**, **"Income"**, **"LoanAmount"**, **"CreditScore"**, **"MonthsEmployed"**, **"NumCreditLines"**, **"InterestRate"**, **"LoanTerm"**, **"DTIRatio"** untuk menyamakan skala antar fiturnya.

Distribusi Target Tidak Seimbang



- Hanya 11% data yang menunjukkan nasabah gagal bayar (default = 1), sisanya 89% adalah lancar.
- Model cenderung bias terhadap kelas mayoritas (lancar), sehingga sulit mendeteksi yang gagal bayar.
- Hal ini menyebabkan model bisa tampak akurat, tapi berbahaya secara bisnis karena gagal mendeteksi nasabah berisiko.



Analisis Distribusi Pendapatan dan Jumlah Pinjaman

Income dan LoanAmount:


- Sebagian besar nasabah memiliki pendapatan dan pinjaman dalam kisaran yang relatif seimbang.
- Tidak terlihat nilai ekstrem karena datanya sudah disesuaikan skalanya.
- Ini menunjukkan bahwa peminjam berasal dari beragam latar belakang keuangan, namun model kami telah menyesuaikan data agar bisa dianalisis secara adil.



Analisis DTI Ratio & Interest Rate


Interest Rate (Suku Bunga Pinjaman):

- Distribusi ini terlihat stabil dan simetris setelah dilakukan proses standardisasi.
- Mayoritas nasabah menerima pinjaman dengan suku bunga yang tidak jauh berbeda, menandakan kebijakan suku bunga cenderung seragam di antara kelompok nasabah.




DTI Ratio (Debt-to-Income Ratio):

- Rasio utang terhadap pendapatan nasabah (DTIRatio) menunjukkan distribusi normal, dengan sebagian besar nasabah berada pada kisaran rasio yang sehat.
- Ini menunjukkan bahwa kebanyakan nasabah masih memiliki kapasitas bayar yang wajar terhadap utang yang mereka ambil.
- Namun, model tetap memperhatikan nilai ekstrem (outlier) karena dapat meningkatkan risiko default.



Kolerasi Antar Faktor

Hasil heatmap menunjukkan bahwa fitur numerik pada dataset ini relatif independen satu sama lain. Tidak ditemukan korelasi yang signifikan atau multikolinearitas, sehingga semua fitur dapat digunakan langsung dalam pemodelan. Korelasi negatif kecil yang muncul hanya bersifat statistik (z-score effect) dan tidak memengaruhi kualitas data.



Perlakuan untuk Data Imbalance


Sebelum penerapan SMOTE, seluruh fitur kategorikal telah diubah menjadi bentuk numerik menggunakan Label Encoding. Kemudian, SMOTE diterapkan terhadap semua fitur numerik dalam data latih untuk memperbanyak sampel dari kelas minoritas (Default = 1). Dengan ini, model dapat belajar lebih baik terhadap pola nasabah berisiko tinggi.

```
[ ] from imblearn.over_sampling import SMOTE
smote = SMOTE(random_state=42)
X_train_resampled, y_train_resampled = smote.fit_resample(X_train, y_train)

print("Sebelum SMOTE:")
print(y_train.value_counts())
print("\nSetelah SMOTE:")
print(pd.Series(y_train_resampled).value_counts())
```

```
Sebelum SMOTE:
Default
0    180555
1     23722
Name: count, dtype: int64
```

```
Setelah SMOTE:
Default
0    180555
1    180555
Name: count, dtype: int64
```



Random Forest

Perlakuan Random Forest Classifier dilakukan setelah melakukan SMOTE. Hasil yang didapatkan ialah :

- Secara umum, model cukup akurat dalam membaca pola data.
- Namun, model masih kesulitan mendeteksi nasabah yang benar-benar berisiko gagal bayar (karena tingkat deteksinya hanya 29%).
- Selain itu, beberapa peringatan yang diberikan model ternyata salah (hanya 32% dari peringatan yang benar).
- Meski begitu, model ini masih cukup baik dalam membedakan mana nasabah yang aman dan yang berisiko, terlihat dari skor pemisahan (ROC AUC) yang berada di atas 0.7.

Pemanfaat pada :

- Cocok digunakan sebagai alat bantu (support system), bukan satu-satunya penentu kredit.
- Bisa digunakan untuk menandai nasabah yang perlu analisis manual lebih lanjut.
- Perlu peningkatan dengan model lain atau tuning threshold agar recall lebih tinggi.

Kelas	Precision	Recall	F1-Score	Support
0 (Tidak Default)	0.91	0.92	0.91	45,139
1 (Default)	0.32	0.29	0.3	5,931
Metrik Umum		Nilai		
Accuracy		0.85		
Macro Avg		0.61 (Precision & Recall)		
Weighted Avg		0.84 (Precision) – 0.85 (Recall)		
ROC AUC Score 0.7299				

XGBoost

Perlakuan XGBoost ini mendapatkan beberapa poin, ialah :

- Kemampuan mendeteksi risiko meningkat tajam, dari sebelumnya hanya 29% (Random Forest) menjadi 63%. Artinya, model ini lebih peka dalam mengenali calon nasabah yang berisiko.
- Nilai ROC AUC sebesar 0.741 menunjukkan bahwa model ini cukup andal dalam membedakan antara nasabah yang aman dan yang berisiko.
- Meski ada penurunan sedikit dalam ketepatan (precision 23%), ini adalah kompromi yang wajar agar nasabah berisiko tidak terlewatkan, terutama untuk keputusan yang menyangkut risiko tinggi.

Pemanfaat pada :

- Digunakan sebagai sistem peringatan dini (early warning system) untuk menandai nasabah yang perlu investigasi lanjutan.
- Dengan sensitivitas yang tinggi terhadap nasabah gagal bayar, XGBoost sangat cocok untuk digunakan sebagai lapisan keamanan tambahan dalam proses pemberian pinjaman.

Kelas	Precision	Recall	F1-Score	Support
0 (Tidak Default)	0.94	0.73	0.82	45,139
1 (Default)	0.23	0.63	0.34	5,931
Metrik Umum		Nilai		
Accuracy		0.71		
Macro Avg		0.58 (Precision & Recall)		
Weighted Avg		0.85 (Precision) – 0.71 (Recall)		
ROC AUC Score 0.74146				

Perbandingan 2 Model

Kelas	Precision	Recall	F1-Score	Support
0 (Tidak Default)	0.91	0.92	0.91	45,139
1 (Default)	0.32	0.29	0.3	5,931
Metrik Umum		Nilai		
Accuracy		0.85		
Macro Avg		0.61 (Precision & Recall)		
Weighted Avg		0.84 (Precision) – 0.85 (Recall)		
ROC AUC Score 0.7299				

Kelas	Precision	Recall	F1-Score	Support
0 (Tidak Default)	0.94	0.73	0.82	45,139
1 (Default)	0.23	0.63	0.34	5,931
Metrik Umum		Nilai		
Accuracy		0.71		
Macro Avg		0.58 (Precision & Recall)		
Weighted Avg		0.85 (Precision) – 0.71 (Recall)		
ROC AUC Score 0.74146				

Kesimpulan Perbandingan Model

Setelah membandingkan dua model, disarankan untuk memilih **XGBoost** karena paling sesuai untuk tujuan utama: **mendeteksi nasabah yang berisiko gagal bayar sejak awal**.

1. Lebih peka terhadap risiko

- XGBoost bisa mendeteksi hampir dua kali lebih banyak nasabah berisiko dibanding model lainnya. Ini sangat penting agar kita bisa menghindari kerugian karena kredit macet.

2. Cukup akurat secara keseluruhan


- Meski ada beberapa “alarm palsu”, XGBoost tetap bisa membedakan mana nasabah aman dan mana yang perlu diwaspadai dengan baik.

3. Membantu ambil keputusan lebih bijak

- Dengan XGBoost, perusahaan bisa lebih percaya diri menilai pengajuan pinjaman, karena model ini mampu melihat pola risiko yang lebih halus dalam data nasabah.

XGBoost adalah pilihan terbaik untuk membantu bisnis menghindari risiko gagal bayar, dengan deteksi yang lebih kuat dan keputusan yang lebih bijak sejak awal proses pengajuan.

Fitur yang Paling Berpengaruh dalam Menentukan Risiko Gagal Bayar



Gambaran ini memberi insight langsung bahwa karakteristik demografis dan kondisi pinjaman sangat memengaruhi hasil prediksi model.

Gambar di samping menunjukkan faktor-faktor yang paling berpengaruh dalam menentukan apakah seorang nasabah berisiko gagal bayar atau tidak, berdasarkan hasil dari model **XGBoost**.

Dari hasil ini, terlihat bahwa yang paling berperan adalah:

- Usia nasabah (Age) – Semakin muda, risikonya cenderung lebih tinggi karena kestabilan finansial biasanya belum terbentuk.
- Suku bunga pinjaman (Interest Rate) – Bunga tinggi seringkali menandakan profil risiko yang lebih besar.
- Adanya penjamin (HasCoSigner) – Jika nasabah memiliki penjamin, maka risikonya dianggap lebih kecil karena ada pihak yang bisa menanggung bila terjadi gagal bayar.



Thank you!